《Python 数据分析编程》课程项目报告

基于时间序列验证与特征消融的城市短期电力负荷预测研究

题目编号：题目四　城市电力负荷分析与预测

小组成员：郑宜桥（25121628）　况子昱（25121631）　徐启翔（25121632）

报告日期：2026 年 11 月

目　录

摘　要 1

1　引言 2

2　数据介绍 3

3　数据清洗与预处理 6

3.1　列名与类型规整 6

3.2　缺失值与重复值 6

3.3　异常值 6

3.4　输出接口 7

4　负荷的时序规律 9

4.1　年内走势 9

4.2　日内规律 10

4.3　周内规律 10

4.4　季节规律 11

4.5　分区对比 12

5　天气因素与负荷的关系 13

5.1　相关系数 13

5.2　温度与负荷的分段特征 14

5.3　与消融结果的呼应 15

5.4　局限 15

6　短期负荷预测：模型、消融与误差分析 16

6.1　预测任务与实验协议 16

6.2　特征与模型 16

6.3　模型比较（表 3、图 7） 17

6.4　归因实验：补上目标时刻对齐的周同期特征 19

6.5 天气特征消融（表 5、图 9） 20
6.6 分区域与高峰时段误差分析（图 8） 22
7 总结与结论 25
7.1 主要发现 25
7.2 对电网调度的建议 25
7.3 局限 26
8 小组成员分工与个人承担 27
8.1 分工表 27
8.2 个人承担说明 27
9 附录 33
附录 A 代码仓库 33
附录 B 复现说明 33
附录 C 主要代码片段 33

摘　要

电力负荷的短期预测是电网调度的基础输入。本项目以某城市 2017 年 1 月 1 日至 12 月 30 日的电力负荷监测数据为对象（共 364 天、52,416 条记录、10 分钟采样、已记录时段内无缺失），包含三个计量区域的负荷与温度、湿度、风速等气象观测。研究按"清洗 → 探索性分析 → 建模预测 → 误差归因"的流程展开：探索性分析发现三个区域共享"凌晨低谷—午间平台—晚间高峰"的日周期结构（峰谷比 1.89–2.23），温度是唯一在三区稳定正相关的气象因子；预测任务定义为提前 1 小时（6 个采样步），按时间顺序 70%/15%/15% 划分数据（并对子集边界做 purge 处理），比较历史同期基线、线性回归与梯度提升树三种模型，并以特征消融检验天气信息的增益。

测试集结果显示：**在最初的特征集下，历史同期基线最优**（三区合并 MAE/RMSE 1050.68/1643.67），两个学习模型均不敌基线。归因实验表明，原特征集未包含与预测目标时刻对齐的周同期负荷信息（基线用的是 y(t−1002)，而学习模型只拿到 y(t−1008)，比目标时刻早一小时），这一特征缺失是原始学习模型表现不佳的重要原因。补上这一特征后，线性回归的合并 MAE/RMSE 降至 514.09/767.16（相对基线 −51.1%/−53.3%），梯度提升树降至 930.62/1258.73（−11.4%/−23.4%），**两个学习模型转为全面优于基线**。天气特征消融在新特征集上重做：六个组合中三个误差下降，梯度提升树三个区域全部下降（−0.4% 至 −17.9%），线性回归在区域 2、3 略升（+5.1%、+1.0%）。高峰时段误差仍约为普通时段的 2.1 倍且系统性低估峰值。基于上述结果，给出了短期调度中优先使用带周同期特征的线性模型、高峰留裕度等建议。

关键词：电力负荷预测；时间序列；特征消融；历史同期基线；梯度提升树

1 引言

电力负荷预测是电网运行调度的基本环节：机组组合、备用容量安排和短期交易决策都依赖未来数小时的负荷估计。负荷受作息、星期、季节和气象条件共同影响，规律性强但也在漂移，短期预测的难点不在于有没有规律可循，而在于用什么特征、什么模型能把这些规律稳定地转化为预测能力。

本项目使用课程提供的城市电力负荷监测数据，完成从数据清洗、探索性分析到预测建模的全流程，重点回答三个研究问题：其一，三个计量区域的负荷在日、周、季节尺度上呈现什么结构，彼此有何差异；其二，温度、湿度等气象因素与负荷的统计关联有多强，能否转化为预测增益；其三，在一个日周期极强、且存在水平漂移的序列上，简单的历史同期基线与线性回归、梯度提升树两种学习模型相比孰优孰劣，误差在区域间和时段间如何分布。

对第三个问题我们不预设答案：学习模型未必优于简单基线，天气特征未必带来增益，一切以同一测试集上的对照实验为准。为使结论可信，全部实验遵循统一协议：按时间顺序划分数据以防泄漏，特征只使用预测起点可获得的信息，模型比较与特征消融共用同一样本集，报告中的每个数字都能追溯到实验日志中的实际运行记录。数据来源、字段与清洗结果见第 2、3 章。

2　数据介绍

（本章取自 report_draft_A.md 第 2 章，数字对应 EXP-20261020-04 及 data_audit.md。）

本项目使用课程提供的城市电力负荷监测数据，文件为单个 CSV，共 52,416 条记录、9 个字段，覆盖 2017 年 1 月 1 日 0 时至 12 月 30 日 23 时 50 分，采样间隔 10 分钟，已记录时段内无中断（数据止于 12 月 30 日，共 364 天，缺 12 月 31 日）。

数据由两类信息组成。一类是三个区域的用电负荷，分别记为区域 1、区域 2 和区域 3；另一类是同一时刻的气象观测，包括气温、相对湿度、风速和两项辐射指标（总漫射辐射、漫射辐射）。所有记录共用同一个时间戳，三个区域的负荷与气象变量在时间上严格对齐，这使得三者可以直接比较，也便于构造滞后特征。

原始数据没有注明负荷与气象变量的单位。气温数值在 3.25 至 40.01 之间，湿度在 11.34 至 94.80 之间，按量纲判断分别为摄氏度和百分比；风速、两项辐射量与负荷的单位则无从确认。因此本报告在涉及绝对数值时一律按原始单位陈述，不做单位换算，涉及区域间比较的结论均使用比值或百分比，不受单位影响。字段的完整说明见表 1。原始列名中，区域 2 与区域 3 的字段名含有连续两个空格，这一细节在第 3 章的数据清洗中单独处理。

表 1　数据字段说明

序号	原始列名	清洗后列名	类型	单位	最小值	最大值	均值	含义
1	DateTime	timestamp	datetime64	—	2017-01-01	2017-12-30	—	时间

序号	原始列名	清洗后列名	类型	单位	最小值	最大值	均值	含义
					00:00	23:50		戳，10分钟采样
2	Temperature	temperature	float64	℃	3.25	40.01	18.81	气温
3	Humidity	humidity	float64	%	11.34	94.80	68.26	相对湿度
4	Wind Speed	wind_speed	float64	未注明	0.0500	6.48	1.96	风速
5	general diffuse flows	general_diffuse_flows	float64	未注明	0.0040	1,163.00	182.70	总漫射辐射
6	diffuse flows	diffuse_flows	float64	未注明	0.0110	936.00	75.03	漫射辐射
7	Zone 1 Power Consumption	zone1_power	float64	未注明	13,895.70	52,204.40	32,344.97	区域1负荷
8	Zone 2Power Consumption	zone2_power	float64	未注明	8,560.08	37,408.86	21,042.51	区域2负荷（原列名含连续

序号	原始列名	清洗后列名	类型	单位	最小值	最大值	均值	含义
								两个空格）
9	Zone 3Power Consumption	zone3_power	float64	未注明	5,935.17	47,598.33	17,835.41	区域3负荷（原列名含连续两个空格）

注：统计范围为 2017 年 1 月 1 日至 12 月 30 日共 364 天的 52,416 条记录。温度与湿度按数值量纲判断为 ℃ 和 %；风速、两项辐射量与负荷的单位原始数据未注明，本表不做推断。

3　数据清洗与预处理

（本章取自 report_draft_A.md 第 3 章，对应 A1/A2 交付。）

3.1　列名与类型规整

原始列名混用了空格、大小写和缩写（如 Wind Speed、general diffuse flows），其中区域 2、区域 3 的列名还带有连续两个空格。清洗时先将连续空白折叠为单个空格、去除首尾空格，再统一映射为小写下划线形式，得到 timestamp、temperature、humidity、wind_speed、general_diffuse_flows、diffuse_flows、zone1_power、zone2_power、zone3_power 共 9 个列名。

原始时间列 DateTime 形如 1/1/2017 0:00，按字符串读入时是 object 类型。用 pandas.to_datetime 解析后转为 datetime64 类型，52,416 条记录全部解析成功，没有出现无法识别的格式。其余 8 个数值字段统一转为 float64，转换过程中没有产生新的缺失值。

3.2　缺失值与重复值

原始数据不含缺失值，52,416 行 × 9 列均完整，因此没有做插值或删除。完全重复的行为 0 条，重复时间戳为 0 个，时间序列严格按 10 分钟等间隔排列，也不存在跨天、跨月的采样中断。这一点在时间序列建模中很重要：如果存在缺测时段，构造 t+6 的预测目标时会出现目标时刻无观测的情况；本数据没有这个问题，可以直接按固定步长构造样本。

3.3　异常值

异常值用 IQR 规则标记，即超出 Q1 − 3×IQR 或 Q3 + 3×IQR 的点。九个字段中共标记 1,708 条，其中 diffuse_flows 1,690 条、zone3_power

18 条，其余字段在 3 倍 IQR 下没有被标记。

对这些点逐类核对后，决定**只标记、不删除、不替换**。diffuse_flows 的极端点集中在 9 时至 16 时以及 2 月和 5 月，正是日照最强的时段和月份，反映的是气象变量的真实波动，删除会削掉白天的信息；zone3_power 的 18 个点集中在 7 月的 19 时至 20 时，对应夏季晚高峰，属于业务上需要重点关注的时段，尤其不能删。清洗阶段另有一项判断：负荷出现负值应视为错误，检查结果为 0 条。标记结果单独写入 anomaly_flags.csv，仅用于说明，不作为模型输入。

3.4　输出接口

清洗后的数据固定输出 9 列，行按时间升序排列、索引重置，写入 data/processed/power_load_clean.csv，列名与类型在 docs/data_interface.md 中固定下来。后续的特征工程、模型训练和误差分析统一从这个文件读取，避免各人按不同假设重复读取原始数据。清洗结果的质量指标汇总在表 2。

表 2　数据质量与清洗情况

检查项	结果	处理方式
原始记录数	52,416	—
字段数	9	—
时间范围	2017-01-01 00:00 至 2017-12-30 23:50	—
时间跨度	364 天	—
采样间隔	10 分钟（1 种）	无需重采样，保持 10 分钟粒度
缺失值	0 个	无缺失，未做插值
完全重复行	0 行	重复行整行删除

检查项	结果	处理方式
重复时间戳	0 个	无重复，不需要去重
负荷负值	0 个	无负值，未做截断
列名规整	2 处	Zone 2 / Zone 3 列名的连续空格折叠为单空格，再统一为 snake_case
类型转换失败	0 个	全部字段可转为数值，无需人工修正
异常值标记（3×IQR）	1,708 条	只标记到 anomaly_flags.csv，不删除、不替换
输出记录数	52,416	行按时间升序，索引重置
其中 diffuse_flows	1,690 条	极端点集中在固定时段，按真实波动保留
其中 zone3_power	18 条	极端点集中在固定时段，按真实波动保留

注：异常值为 3 倍四分位距规则的统计标记，仅用于提示，清洗阶段不做删除或替换；负荷峰值属真实用电行为，保留原值。

4　负荷的时序规律

（本章取自 report_draft_A.md 第 4 章，对应图 1–4 与 eda_findings.md。）

4.1　年内走势

三个区域的负荷水平差距明显。年内日均值分别为 32,345、21,043 和 17,835，区域 1 约为区域 3 的 1.8 倍，且这一量级关系在年内稳定（图 1）。季节形态则三个区各不相同：区域 1 最平缓，最高月比最低月高约两成半；区域 2 在 7、8 月形成夏季峰，11、12 月又出现一个高于春季的次高峰；区域 3 起伏最剧烈，7 月达到 28,200，12 月降至 11,000，最高月是最低月的 2.6 倍。按季节平均，区域 3 夏季负荷是冬季的 1.59 倍，区域 1 和区域 2 分别只有 1.17 和 1.12 倍。

区域 3 从 9 月到 12 月的连续下滑需要谨慎对待：其中既有季节性成分，也可能包含全年负荷水平的整体下移，本数据只有一个年度周期，两种成分无法分离，因此按观测值陈述，不做季节性归因。负荷水平的年内下移是可以确认的：区域 1 在训练期的日均值为 33,065，测试期为 29,056。这一事实直接关系到第 6 章的数据划分方式。

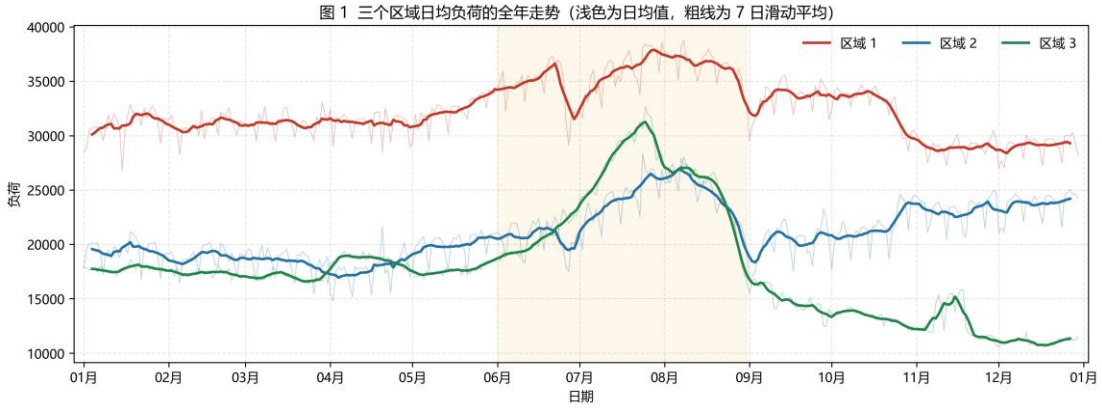


图 1　三个区域日均负荷的全年走势

2017 年 1 月 1 日至 12 月 30 日，52,416 条 10 分钟观测按日取均值；浅色线为日均值，粗线为 7 日滑动平均；阴影区间为 6—8 月。

4.2 日内规律

三个区域的峰谷时刻高度一致，谷值出现在 6 至 7 时，峰值出现在 20 时。区域 1 和区域 2 的峰谷比为 1.89，区域 3 为 2.23（图 2）。曲线呈"凌晨低谷、午间平台、晚间高峰"的三段结构，并非典型双峰。

工作日与周末的差距主要落在白天：区域 1 晚高峰时段工作日与周末仅差 2.8%，全天差距 3.6%；区域 2 差别更明显（6.2% 与 8.2%）；区域 3 几乎没有区别。峰值时刻的日间稳定性很高：三个区分别有 98.9%、97.5%、99.2% 的日子全天最高负荷落在 18 至 21 时。日峰值本身的波动则差别明显：变异系数区域 1 为 7.4%、区域 2 为 12.5%、区域 3 高达 27.7%——这一差别解释了第 6 章分区域误差的分布：区域 3 难预测，主因不在模型，而在目标序列自身的波动幅度。

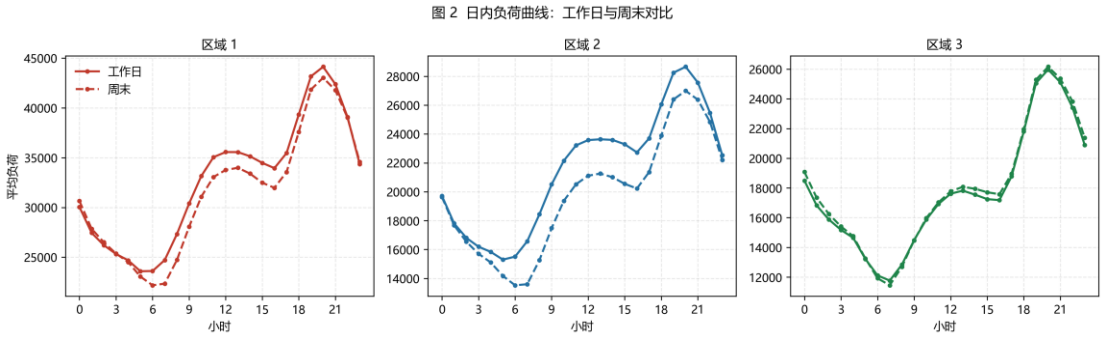


图 2　日内负荷曲线：工作日与周末对比

已记录时段内观测按小时取均值，实线为工作日，虚线为周末；三个子图的纵轴范围各自独立，不宜直接比较幅度。

4.3 周内规律

区域 1 和区域 2 的周内走势一致：周一至周四持平，周五开始走弱，周日最低，工作日与周末的比值分别为 1.04 和 1.09。区域 3 的走向相反，

周五反而是全周最低，工作日与周末比值 0.99，实际不存在星期效应（图 3）。这一差异决定了星期特征对区域 3 的贡献有限。

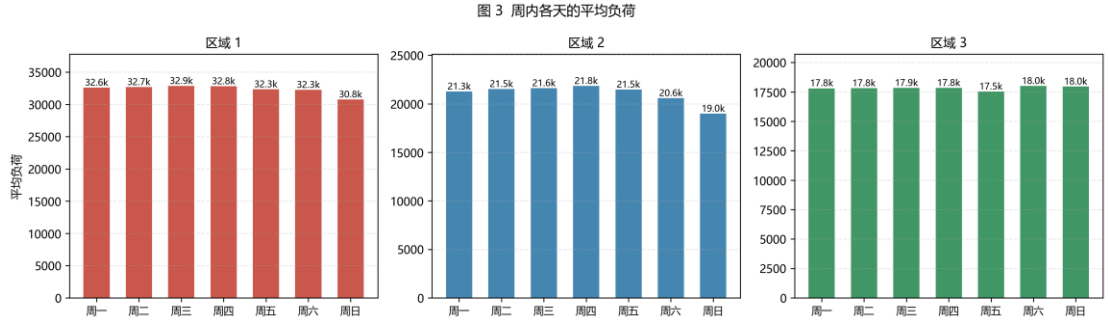


图 3　周内各天的平均负荷

已记录时段内观测按星期取均值；三个子图纵轴范围独立，跨区域比较请参见第 4.5 节汇总表。

4.4　季节规律

按月统计的箱线图显示，中位数的月度走势与日均值一致，但箱体高度在夏季明显变大，说明夏季不仅负荷水平高，日内波动和日间差异也都大于冬季（图 4）。各区极值月份：区域 1、2 最高月在 8 月，区域 3 在 7 月；最低月区域 1、3 分别为 11、12 月，区域 2 的低谷却出现在 4 月——该区域冬季负荷并不低，真正的低谷在春季。

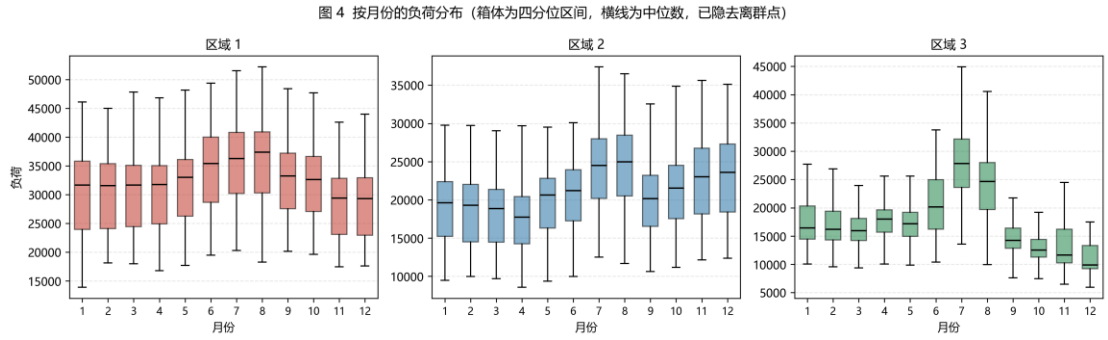


图 4　按月份的负荷分布

已记录时段内 10 分钟观测按月份绘制的箱线图，箱体为四分位区间，横线为中位数，须线延伸至 1.5 倍四分位距，离群点已隐去；三个子图纵轴范围独立。

4.5　分区对比

指标	区域 1	区域 2	区域 3
年内日均	32,345	21,043	17,835
峰时 / 谷时	20 时 / 6 时	20 时 / 6 时	20 时 / 7 时
峰谷比	1.89	1.89	2.23
周末相对工作日	−3.6%	−8.2%	+1.2%
夏冬比	1.17	1.12	1.59

三个区共享同一套时间结构，差别集中在幅度上：区域 1 量级最大、曲线最平稳；区域 2 星期效应最强且冬季有次高峰；区域 3 量级最小，季节性和日内波动都最强。建模时应当区别对待，而不是对三个区套用同一组特征。

5　天气因素与负荷的关系

（本章取自 report_draft_A.md 第 5 章，对应图 5-6 与 weather_findings.md。）

5.1　相关系数

三个区域的负荷与五个气象因子的相关系数见图 5 与下表（括号外 Pearson，括号内 Spearman）。

因子	区域 1	区域 2	区域 3
温度	+0.44（+0.43）	+0.38（+0.38）	+0.49（+0.44）
湿度	−0.29（−0.30）	−0.29（−0.31）	−0.23（−0.21）
风速	+0.17（+0.11）	+0.15（+0.09）	+0.28（+0.08）
总漫射辐射	+0.19（+0.26）	+0.16（+0.24）	+0.06（+0.08）
漫射辐射	+0.08（+0.12）	+0.04（+0.10）	−0.04（−0.02）

温度是唯一在三区都稳定为正的因子。风速和总漫射辐射的两种系数差距较大（如区域 3 风速 Pearson 0.28、Spearman 仅 0.08），说明其数值主要由少数极端时段支撑，放进线性模型并不可靠。三个区域负荷之间的相关系数在 0.75 至 0.84 之间，说明三区受共同因素驱动。

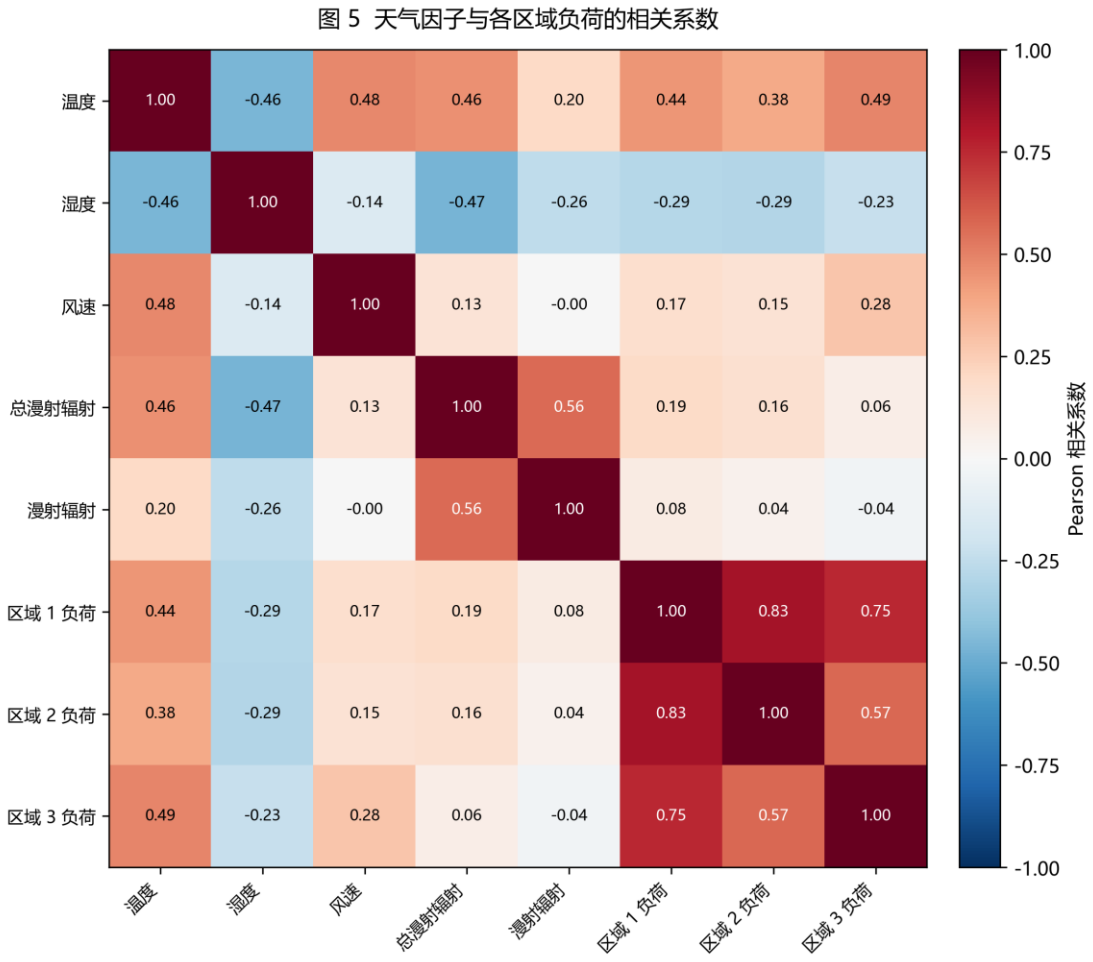


图 5　天气因子与各区域负荷的相关系数

已记录时段内 52,416 条观测计算的 Pearson 相关系数；色标固定为 −1 至 1，对角线为变量自身相关，数值恒为 1。

5.2　温度与负荷的分段特征

分箱均值显示（图 6）：6 ℃ 至 33 ℃ 区间负荷随温度单调上升，33 ℃ 以上进入平台。温度从 6.5 ℃ 升到 33.5 ℃ 时，区域 1、2 的分箱均值各上升 69%，区域 3 上升 158%，与它夏冬比 1.59、峰谷比 2.23 的结论一致。数据中**没有观察到典型的 U 形**：3 ℃ 至 5 ℃ 的负荷并不高于 20 ℃ 附近，说明这三个区域的用电对低温不敏感，温度特征在冬季的作用有限。

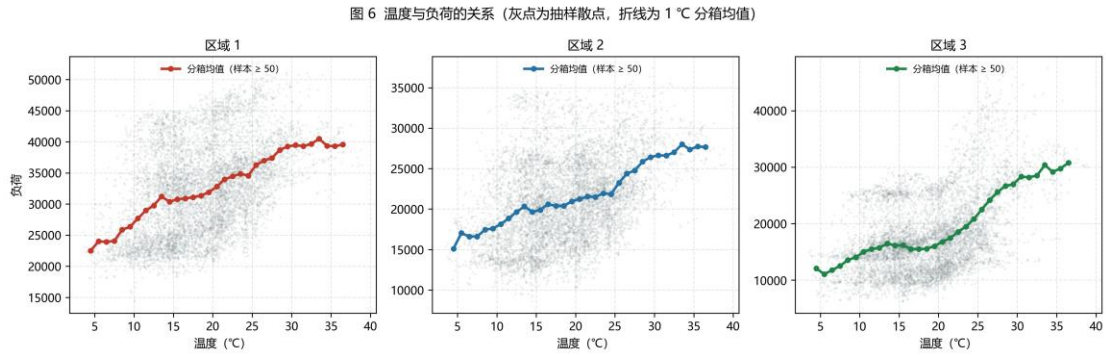


图 6　温度与负荷的关系

灰点为从已记录时段观测中随机抽样的 8,000 条记录，折线为按 1 ℃ 分箱后的负荷均值，仅保留样本量不少于 50 的区间；三个子图纵轴范围独立。

5.3　与消融结果的呼应

第 6 章的消融实验显示，在原始特征集上，线性回归加入天气特征后区域 3 的测试集 RMSE 下降 34.6%，是三个区里降幅最大的；区域 2 只下降 4.1%。这一排序与本节的相关性排序一致：温度相关性最高的区域，天气特征带来的收益也最大。两条独立证据互相印证。需要说明的是，这一增益是在模型尚未获得目标对齐周同期特征时测得的；补上该特征后天气的边际增益明显缩小（详见 6.5），本节的结论应理解为"温度与负荷的统计关联确实存在"，而非"天气特征在任何特征集下都有同等增益"。

5.4　局限

以上只描述统计共变，不构成因果判断。未对节假日建模，未区分昼夜，相关系数未做去趋势处理（年内负荷下移会使系数略微偏低）。

6　短期负荷预测：模型、消融与误差分析

6.1　预测任务与实验协议

预测任务定义为**提前 1 小时**预测：对预测起点 t，目标是其后第 6 个时间步（t+6）的负荷。三个区域分别建样本、分别训练、分别评价。数据按预测起点的时间顺序划分为训练/验证/测试三部分，比例 70%/15%/15%，实际边界为：训练集至 2017-09-14 19:40（35,975 个起点），验证集至 11-07 08:40（7,704 个），测试集至 12-30 22:50（7,711 个），三区域共用同一套切分。

边界 purge。 目标在起点之后一小时，如果只按起点切分，子集末尾若干起点的标签时刻会落到下一个子集的起点区间内——训练集末尾的标签会被验证集"看到"，验证集末尾同理。为此训练集与验证集末尾各剔除 6 个起点（共 12 个样本不进入任何子集）。剔除后：训练末起点的目标时刻（09-14 20:40）早于验证集首起点（09-14 20:50），验证末起点的目标时刻（11-07 09:40）早于测试集首起点（11-07 09:50），任一子集的标签区间与下一子集的起点区间不再重叠。该断言已写入 verify_against_plan() 与自动化检查。测试集区间不受影响，历史同期基线的指标与剔除前完全一致。

防泄漏规则：所有特征只使用预测起点 t 及更早的观测；滚动统计一律回溯窗口；标准化等拟合型预处理只在训练集上拟合；验证集用于选型选参，测试集只评一次。天气特征取起点时刻的同步观测（协议约定，实际部署应替换为天气预报）。

6.2　特征与模型

特征分三组。历史负荷组：当前负荷、1 小时前、24 小时前同期、7 天前同期（load_lag_0/6/144/1008）；时间组：小时、星期、月份及其周期编

码；天气组：起点时刻的温度、湿度、风速与两项辐射。历史同期基线不消费特征，直接取目标时刻的上一周同期值 y(t+6−1008)。

这里埋着一个容易被忽略的口径差异：基线取的是 y(t−1002)，即**目标时刻**往前一周；而特征组里的 load_lag_1008 是起点往前一周，比目标时刻再早一小时。两个学习模型因此没有直接拿到基线所使用的那条记录。6.4 节专门检验这一点，并在 6.5 节之后改用修正后的特征集。

三个模型：**历史同期基线**（无训练、无超参）；**线性回归**（标准化 + 最小二乘，无超参）；**梯度提升树**（scikit-learn HistGradientBoostingRegressor，在验证集上对小规模参数网格选优，随机种子 42）。评价指标为 MAE / RMSE / MSE，按（模型 × 区域）在测试集上分别计算，并给出三区合并口径。

版本一致性。 梯度提升树的数值结果会随 scikit-learn 版本发生微小漂移。全组统一锁定 scikit-learn==1.6.1 后，消融实验中"含天气"组的指标与主实验**逐值一致**（线性回归本就确定性可复现）；此前记录的 0.3% – 3.1% 偏差系版本不同所致，已随本次重跑消除。

6.3 模型比较（表 3、图 7）

表 3　三个模型在测试集上的对比（原特征集）

注：测试集为 2017-11-07 09:50 至 2017-12-30 22:50，每区域 7,711 个样本；加粗为同区域最优；MSE 按逐点预测误差平方的均值计算，RMSE 为其平方根，各指标均由未舍入结果计算后再显示舍入。

模型	Z1 MAE/RMSE	Z2 MAE/RMSE	Z3 MAE/RMSE	合并 MAE/RMSE	合并 MSE
历史同期基线	831.04 / 1151.45	966.29 / 1366.37	1354.70 / 2216.34	**1050.68 / 1643.67**	**2,701,655**
线性回归	2143.03 /	1016.45 /	**1321.49 /**	1493.66 /	3,831,677

模型	Z1 MAE/RMSE	Z2 MAE/RMSE	Z3 MAE/RMSE	合并 MAE/RMSE	合并 MSE
	2512.61	1550.16	**1666.97**	1957.47	
梯度提升树	1596.96 / 2255.25	1091.57 / 1728.73	1840.15 / 2233.54	1509.56 / 2086.73	4,354,460

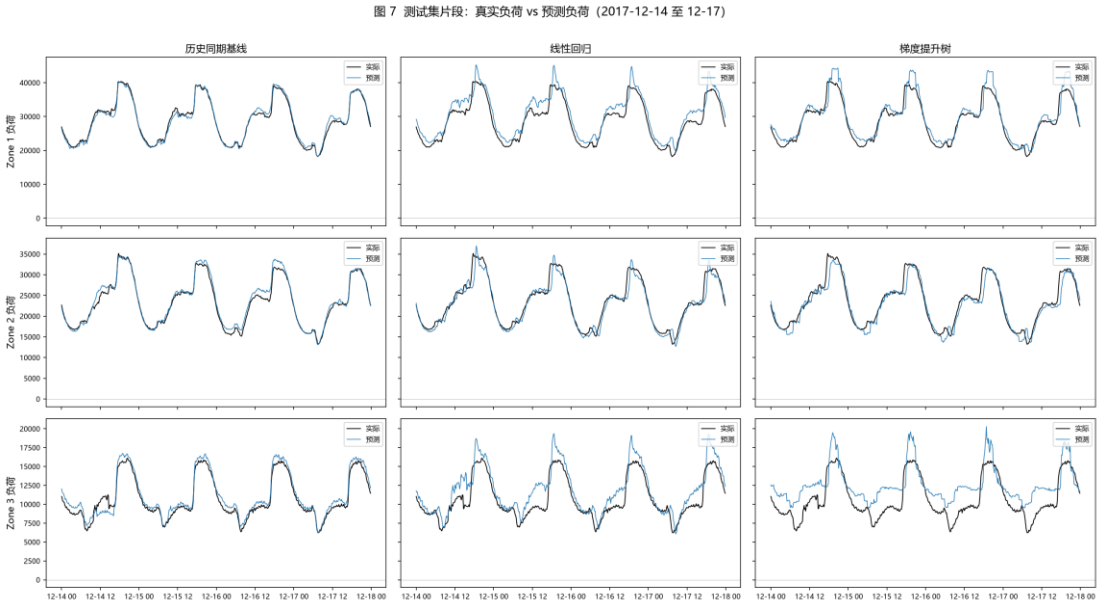


图 7　测试集片段：真实负荷与预测负荷对比

2017 年 12 月 14 日至 12 月 17 日的局部片段，三行分别为三个模型、三列为三个区域；完整测试区间的指标见表 3。

MSE 根据测试集逐点预测误差的平方计算，RMSE 为 MSE 的平方根。表中指标分别由未舍入的原始结果计算后再进行显示舍入；逐区 MSE 见 outputs/metrics/report_table3.csv。三个指标各有侧重：MAE 反映平均绝对偏差，RMSE 与 MSE 对大误差更敏感（平方项放大极端值），三者排序一致时结论更稳健。

十二个（模型 × 区域 × 指标）组合中，仅线性回归在区域 3 的 MAE 与 RMSE 同时优于基线（−2.45% 与 −24.79%），其余十项基线占优。基线占优的原因有二：其一，日周期极稳定（97% 以上的日子峰值落在 18–21 时），"上周同一时刻"本身就是很强的预测量；其二，测试期负荷水平较训练期下

移（区域 1 日均 33,065→29,056，区域 3 20,052→11,949），学习模型外推训练期水平产生系统性偏差，而基线锚定上周同期值，天然免疫这种漂移。

但这还不能下结论说"学习模型不适合这个任务"。因为两个学习模型手里的周特征与基线并不同源（见 6.2）：基线看的是目标时刻的上一周，它们看的是起点的上一周。下一节专门检验这一点。

6.4 归因实验：补上目标时刻对齐的周同期特征

在特征集中新增一项 load_lag_target_week = y(t−1002)，即历史同期基线所用的那条记录。该值在预测起点时已经是历史观测（t−1002 远早于 t），不构成未来信息；原有的 load_lag_1008 保留，样本、切分、模型配置、评价指标全部不变，因此差异只能归因到这一项特征。

表 4 归因实验：补上目标对齐周同期特征后的测试集指标

注：样本、切分、模型配置与评价指标与主实验完全一致，唯一差别是新增一项 load_lag_target_week = y(t−1002)；MSE 为三区合并口径。

模型	Z1 MAE/RMSE	Z2 MAE/RMSE	Z3 MAE/RMSE	合并 MAE/RMSE	合并 MSE
历史同期基线	831.04 / 1151.45	966.29 / 1366.37	1354.70 / 2216.34	1050.68 / 1643.67	2,701,655
线性回归（+ 周同期）	**547.15 / 777.86**	**513.58 / 729.94**	**481.52 / 792.29**	**514.09 / 767.16**	**588,534**
梯度提升树（+ 周同期）	925.93 / 1201.90	762.60 / 1118.37	1103.33 / 1434.54	930.62 / 1258.73	1,584,408

括号内的相对变化均为相对历史同期基线；MSE 为合并口径。

结果远超预期：加入该特征后，线性回归在三区的测试集 RMSE 相对原特征集下降 52.5%–69.0%，相对基线下降 32.4%–64.3%，合并口径 MAE/RMSE 由 1493.66/1957.47 降至 514.09/767.16（−51.1%/−53.3%）；梯

度提升树相对基线除区域 1 略高（+4.4%）外，区域 2、3 分别下降 18.2% 和 35.3%，合并口径 −11.4%/−23.4%。**两个学习模型转为全面优于基线**。

这说明 6.3 的结论需要修正：此前"学习模型不敌基线"并不是模型不合适，而是特征集没有把最重要的周期性信息交给模型——基线之所以强，恰恰因为它直接复制了目标时刻的上一周同期值。修正特征口径后，学习模型既能利用这条信息，又能用天气、小时等其他特征做修正，因此超过了只会照抄的基线。这一结果也提示：在日周周期极强的数据上做模型比较时，必须先确认基线和学习模型拿到的信息是否同源，否则容易得出"简单基线不可战胜"的误判。

6.5　天气特征消融（表 5、图 9）

由于 6.4 已确认应改用含目标对齐周特征的特征集，消融随之在新特征集上重做：A 组 = 历史（含周同期）+ 时间特征，B 组 = A 组 + 天气特征，除天气开关外样本、切分、模型、参数完全一致。

表 5　天气特征消融结果（含周同期特征的新特征集）

注：数值为含天气特征组（B 组）相对不含天气特征组（A 组）的测试集 RMSE 变化，负值表示误差下降；加粗的三个组合误差反而上升，为如实报告。

模型	区域	测试集 RMSE 变化
线性回归	Z1 / Z2 / Z3	−10.99% / **+5.08%** / **+0.98%**
梯度提升树	Z1 / Z2 / Z3	−17.85% / −5.94% / −0.43%

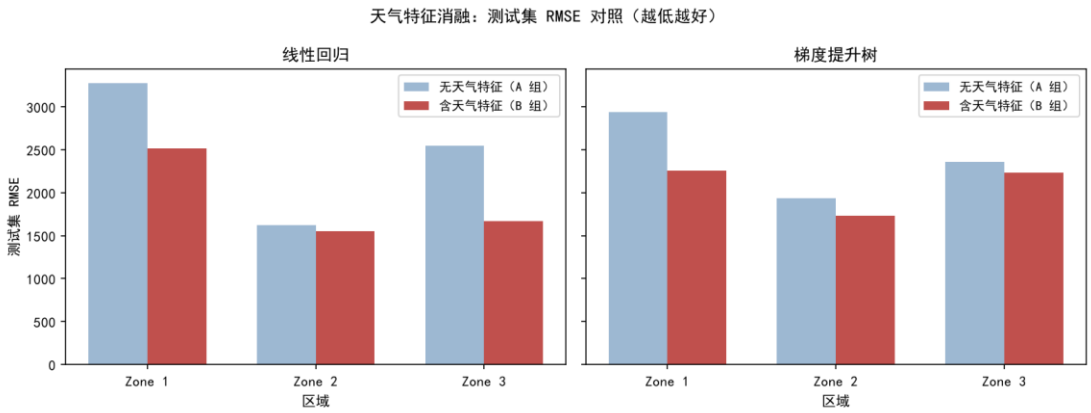


图 9（a） 天气特征消融：原特征集下的测试集 RMSE 对照

六个（模型 × 区域）组合的测试集 RMSE，柱高越低越好；深色为含天气特征组，浅色为不含天气特征组。

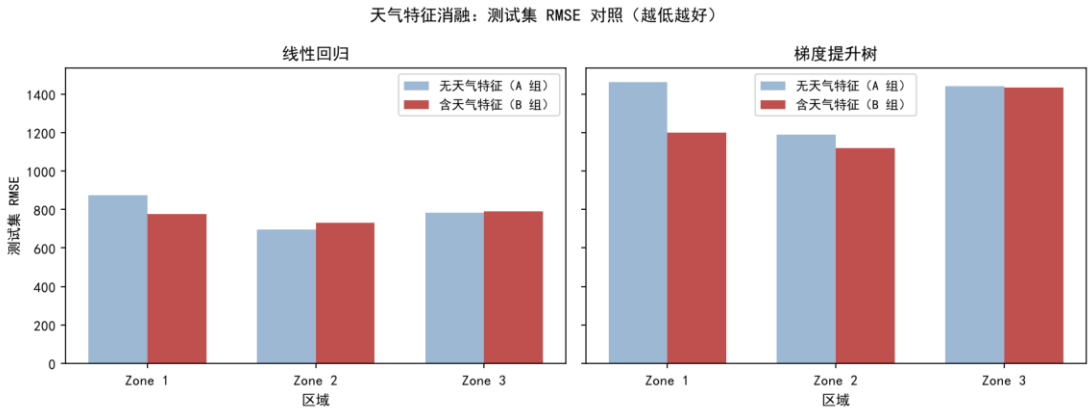


图 9（b） 天气特征消融：含周同期特征的新特征集下的测试集 RMSE 对照

与（a）同一消融在新增 load_lag_target_week 后重跑的结果；两图纵轴刻度不同，比较幅度请见表 5。

作为对照，在原特征集（不含周同期）上同一消融的结果是：线性回归 −23.30% / −4.24% / −34.56%，梯度提升树 −23.18% / −10.54% / −5.22%，六个组合中五个下降。

两组结果放在一起看，结论要谨慎：**天气特征的增益依赖于模型已经掌握了多少周期性信息**。在原本的模型上，天气特征填补了缺失的周期信息，因而显得很有用（最多 −34.6%）；一旦把周同期特征直接交给模型，天气带

来的边际增益就大幅缩小，六个组合中三个下降（梯度提升树三个区域全部下降，−0.4% 至 −17.9%），线性回归在区域 2、3 反而略升（+5.1%、+1.0%）。因此本报告的结论是：天气特征确实有增益，但**在周同期特征已存在的前提下增益有限，且因区域和模型而异**，不宜概括为"天气特征显著改善预测"。天气仅用预测起点的同步观测，实际部署时应替换为天气预报，届时增益预计进一步打折。

6.6　分区域与高峰时段误差分析（图 8）

以下分析基于 6.4 之后的推荐模型（含周同期特征）。消除量级差异后按 nRMSE 比较：线性回归为 2.68% / 3.10% / 6.63%，梯度提升树为 4.14% / 4.75% / 12.01%，历史同期基线为 3.96% / 5.81% / 18.55%。区域 3 对三个模型都最难，与第 4 章的发现一致（日峰值变异系数 27.7%）；线性回归在三区都是最优，且把区域 3 的相对误差从基线的 18.55% 压到 6.63%。

系统性偏差（bias = 预测 − 实际）方向不一：线性回归为 +86 / −223 / −173，梯度提升树为 +522 / −271 / +549，基线为 −17 / −109 / +108。加入周同期特征后，此前学习模型在区域 1、3 的严重高估（+1020 / +1670）已大幅收敛。

高峰时段（阈值取训练集负荷分布 Q90）分析：区域 2 高峰时段梯度提升树 RMSE 为 1732，是普通时段（825）的 2.1 倍，且偏差由 −100 转为 −793——模型在高峰时段系统性低估峰值，这是对电网调度最不安全的误差方向，这一结论在特征修正后**依然成立**。区域 1 测试期高峰样本仅 9 条、区域 3 为 0 条（测试期负荷整体下移），这两个区域的高峰表现无法从本次数据确认。

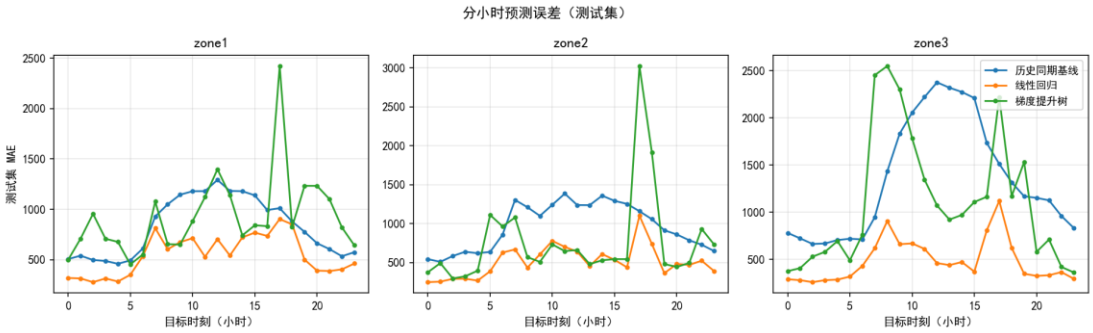


图 8（a）　分小时预测误差（测试集）

按目标时刻的小时统计 MAE，三个区域各一子图；基于含周同期特征的推荐模型。

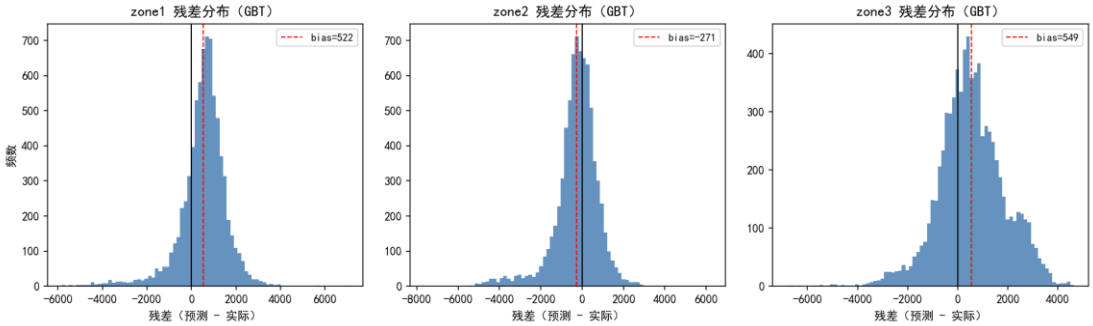


图 8（b）　残差分布（梯度提升树）

残差 = 预测 − 实际，横轴为残差，纵轴为频数；三个区域各一子图。

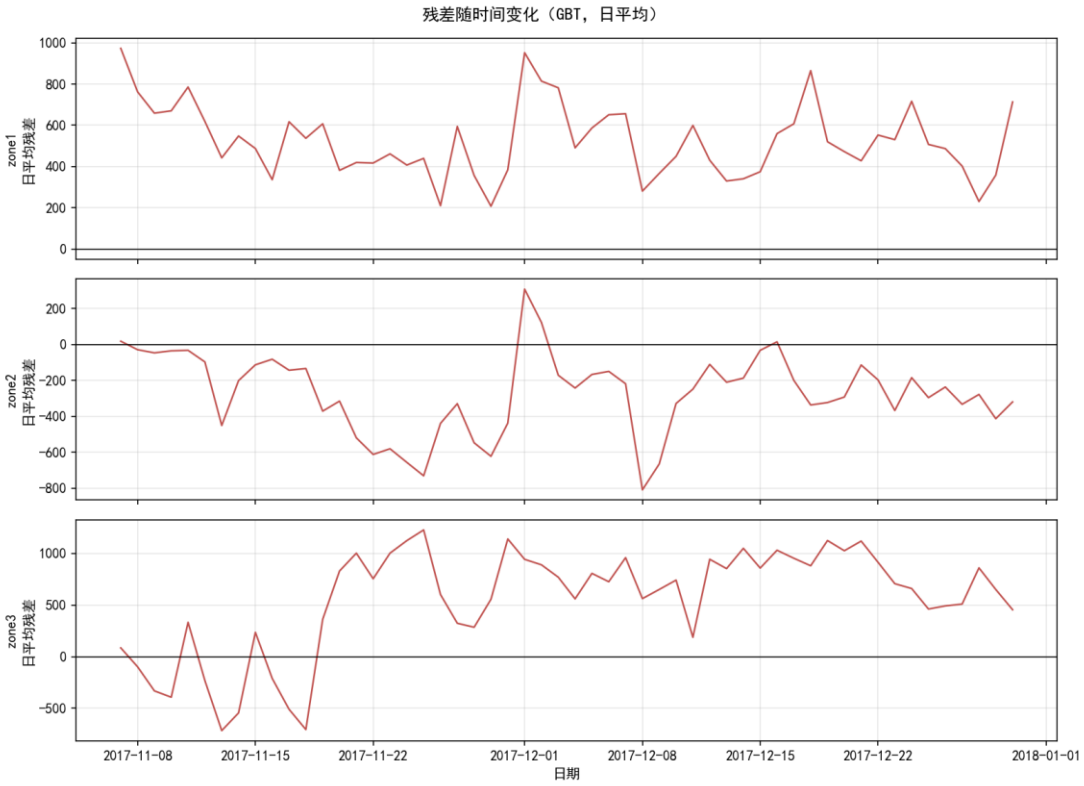


图 8（c） 残差随时间变化（梯度提升树，日平均）

测试集残差按日取均值后按日期排列，用于检查误差是否随时间漂移。

7　总结与结论

7.1　主要发现

1. **"学习模型不敌基线"是特征口径问题，不是模型问题。** 在原始特征集下基线最优（合并 MAE/RMSE 1050.68/1643.67），但基线用的 y(t−1002) 与学习模型手里的 y(t−1008) 并不同源。补上目标时刻对齐的周同期特征后，线性回归降至 514.09/767.16（−51.1%/−53.3%）、梯度提升树降至 930.62/1258.73（−11.4%/−23.4%），两个学习模型全面反超基线。这是本项目最重要的一条结论：**做模型比较前必须先确认基线和学习模型拿到的信息是否同源。** 2. **三个区域的预测难度差异主要来自数据本身。** 改进后区域 3 的 nRMSE 仍最高（线性回归 6.63%，基线 18.55%），与其日峰值变异系数 27.7% 一致；区域间比较必须使用相对指标。 3. **天气特征的增益依赖模型已掌握多少周期信息。** 原特征集上 5/6 组合下降（最多 −34.6%），补上周同期特征后仅 3/6 下降（梯度提升树三区全降 −0.4% 至 −17.9%，线性回归在区域 2、3 略升）。不宜概括为"天气特征显著改善预测"。 4. **高峰时段更难预测且方向不利。** 区域 2 高峰误差为普通时段 2.1 倍，且系统性低估峰值（bias 由 −100 转为 −793），这一结论在特征修正后依然成立；区域 1、3 因样本不足无法确认。

7.2　对电网调度的建议

- 小时级调度优先使用**带目标对齐周同期特征的线性回归**：测试集三区合并 MAE/RMSE 最低，且三区 nRMSE 均为三者最小； - 历史同期基线可作为无训练、无维护成本的兜底方案，但精度比改进后的线性模型低一半以上； - 高峰时段（18–21 时）模型倾向低估，调度裕度应向高估方向留，尤其区域 2； - 区域 3 波动最大、预测最难，建议单独监控并保留更大备用容量；

- 引入天气预报替换同步观测时收益有限，建议先把周同期特征与实时负荷接入做扎实，再评估天气投入。

7.3 局限

本数据仅覆盖一个城市、一年（364 天，缺 12 月 31 日），以下结论不能外推：跨城市、跨年度的一般规律；跨年度季节性断言（区域 3 的 9–12 月下滑含趋势成分，无法与季节性分离）；采暖季模型有效性（未观察到低温 U 形回升）；节假日与极端天气下的表现（样本极少）。全部对比仅报数值与相对变化，未做显著性检验，不使用"显著"一类措辞。

另有两点方法上的限定需要说明。其一，6.4 的大幅改善高度依赖日周周期的稳定性（97% 以上的日子峰值落在 18–21 时），在作息规律较弱或负荷波动更剧烈的场景下，周同期特征的增益预计会小于本数据的观测值。其二，y(t−1002) 与天气特征一样，取的是预测起点时的**历史**观测，不构成未来信息；实际部署时它与基线所需的数据完全相同，因此不额外增加获取成本，但如果当日存在检修、节假日等已知的日程突变，两个模型都会失效，需要另行加入日程特征。每条结论的证据与图表对应关系见 docs/results_conclusions.md 的对照表。

8　小组成员分工与个人承担

8.1　分工表

成员	学号	承担章节 / 模块	具体工作内容
郑宜桥	25121628	第 2、3、4、5 章；数据模块	数据审计、清洗与接口定义、日/周/季节规律分析、天气与负荷关系分析、表 1 与表 2
况子昱	25121631	第 6 章；模型模块	预测协议、时间切分与特征、基线与梯度提升模型、模型比较与交付检查
徐启翔	25121632	摘要、第 1、7 章；消融与误差分析	报告框架与整合、天气特征消融、分区域与高峰时段误差分析、汇报材料

8.2　个人承担说明

郑宜桥（成员 A）

承担部分。 第 2 章数据介绍、第 3 章数据清洗与预处理、第 4 章负荷时序规律、第 5 章天气与负荷关系，以及对应的代码：数据审计、清洗模块、时序分析、天气分析、报告表格生成。代码提交对应仓库中的 A1 至 A4 与表格、报告两次提交。

分析思路。 动手前先把数据摸清楚，再决定怎么处理。原始数据给到时只有字段名，没有说明文档，时间特性、量级范围、字段之间是否对齐都不确定。如果跳过审计直接写清洗规则，很容易按经验拍脑袋，比如想当然地补缺失值、按固定阈值裁掉高峰。所以我把顺序定为：先出一份质量报告，把行数、时间范围、采样间隔、缺失重复、各字段分布都摊开；再依据报告确定清洗规则；清洗结果定型后才做分析。分析也按同一逻辑推进，先看时

间维度上的规律，再看气象因素，因为时间规律是负荷自身最稳定的结构，不先确定它，讨论天气影响就没有基准。

方法与步骤。 审计阶段逐项检查了字段类型与缺失、时间戳解析与重复、采样间隔是否一致、负荷与气象字段的极值与分布，并用四分位距标出极端点。清洗阶段统一列名为小写下划线形式，把时间列解析为标准时间类型，数值列强制转换并记录失败数，完全重复行删除，同一时间戳对应不同数值的情况默认报错而不是静默取值。异常点单独写入一个标记文件，主数据保持原值。分析阶段按小时、星期、月份分组求均值，画日内曲线、周内柱状图、月度箱线图；天气部分计算 Pearson 与 Spearman 两种相关系数，并对温度按 1 ℃ 分箱求负荷均值。报告中的表格由脚本从数据直接生成，不手工填写。

遇到的问题与解决。 有三个。

一是列名里藏了连续两个空格。区域 2 和区域 3 的字段名中间是两个空格，写代码时按字符串取列一直报错，肉眼又看不出来。后来改成先把所有列名规范化（折叠连续空白、去首尾空格、转小写），再用映射表对应到统一列名，问题才解决。这件事让我在清洗模块里加了一道检查：规整后如果出现重名列就直接报错，避免静默覆盖。

二是异常值该不该删。按四分位距标记出 1,708 个极端点，其中漫射辐射一项占了 1,690 个。最初的直觉是删掉，但把这些点按小时和月份汇总后发现，它们集中在上午 9 点到下午 4 点、以及 2 月和 5 月，正是日照最强的时段。漫射辐射本身受太阳高度角控制，用全年分布去衡量，晴天正午的数据自然被判为离群。这类点是物理规律，不是录入错误。另一批极端点在区域 3 的 7 月 19 时至 20 时，对应夏季晚高峰，更是不能删。最后决定只标记不删除，把判断依据写进报告第 3 章。

三是三个区域量级差得太多。区域 1 的日均负荷是区域 3 的 1.8 倍，画在同一张图里，区域 3 的曲线形状被压平，看不出细节。分开画又带来新问题：三个子图的纵轴范围不一样，读者容易误以为可以直接比较幅度。最后的处理是子图各自独立纵轴、保留形状差异，同时在报告里单独做一张分区特征汇总表，把峰谷比、周末效应、夏冬比等比值列出来，跨区域比较一律走这张表，图注里也写明纵轴不统一。

不足。 原始数据没有标注负荷与气象变量的单位，报告里所有跨区域比较只能使用比值，绝对量级的讨论无法展开。另外，区域 3 从 9 月到 12 月的连续下滑，既可能是季节性，也可能是全年负荷水平的整体下移。数据只有一个年度周期，这两类成分在现有数据上分不开，我在报告中如实写明“无法分离”，没有做季节性归因。如果后续能拿到多年数据，用同月对比或去趋势处理可以进一步区分。

况子昱（成员 B）

承担部分。 第 6 章的预测协议与模型模块：时间切分、特征构造、历史同期基线、线性回归与梯度提升树、统一比较入口，以及配套的自动化检查。代码对应 B1 至 B6 六次提交。

分析思路。 预测任务最怕的不是模型差，而是把未来的信息喂给了模型，得出一个好看但没用的数字。所以动手写模型之前，先把协议定下来：目标定在起点之后 1 小时，数据按时间顺序切，特征只能取起点及更早的观测，验证集用来选参数、测试集只在最后评一次。协议写进文档后，后续每一步都拿它对照，包括后来成员 C 的消融和误差分析也复用同一套切分和特征接口，不另起炉灶。

方法与步骤。 先按 70%/15%/15% 按时间切出训练、验证、测试三段，

边界固定在 2017-09-14 20:40 与 11-07 09:40；再实现特征构造的开关，历史负荷、时间编码、天气三组可分别开关，供后面消融使用；然后依次实现基线、线性回归、梯度提升树，统一训练与预测接口，最后用一个入口脚本重跑三模型并输出比较表与图 7。检查部分写成可执行的测试：三模型测试区间是否完全一致、特征索引是否越界、预测文件字段是否合规、指标能否从预测文件复算出来。

遇到的问题与解决。 有三个。

一是基线的索引差一位。历史同期基线看似简单，但目标时刻是 t+6，"上一周同期"应该是 y(t+6−1008) 也就是 y(t−1002)，不是 y(t−1008)。写错一位就变成了错开一小时的比较，指标会虚高。最后是靠测试逐值比对清洗数据才确认下来的。

二是梯度提升树跑得太慢。经典实现单区域训练要 40 到 108 秒，参数网格一铺开就不可接受了。换成同一库的直方图版本后降到 0.5 到 3.5 秒，快了约 30 倍，算法族没有变，这一决策按协议里的备选条款执行并记进了实验日志。

三是交付前发现成员 C 机器上的梯度提升树结果与本机对不上，相对差异在 0.3% 到 3.1% 之间。逐层排查后排除了数据、切分和参数，确认是 scikit-learn 版本不同导致的数值微差，线性回归和其他结构性指标全部逐值一致。这件事没有掩盖，写进了交付报告，并建议全组锁定版本。

不足。 数据没有天气预报字段，起点的天气只能用同步观测代替，这是所有天气特征结论的前提，报告里必须写明。另外候选扩展特征（半小时滞后、24 小时滚动均值等）已经实现但默认关闭，没有进入主实验。

徐启翔（成员 C）

承担部分。 摘要、第 1 章引言、第 7 章结论，第 6.4 节的归因实验、第 6.5 节的天气特征消融、第 6.6 节的分区域与高峰时段误差分析，以及报告框架、实验记录规范和最后的整合定稿。代码对应 `src/ablation.py`、`src/error_analysis.py` 与 `src/probe_target_week.py`，提交为 C1 至 C5。

分析思路。 三个人各写各的，最后要并到一份报告里，最怕的是口径对不上。所以第一件事不是跑实验，而是先把框架和记录规范立下来：章节怎么分、图表编号怎么排、每次实验要登记哪些字段。这样后面每个人产出的数字都能追溯到某一条日志记录，整合时不需要再猜。做消融和误差分析时同样先定规则再动手：消融只改一个开关，其余完全不动；误差分析不另建测试集，直接读成员 B 已经生成的预测文件；高峰阈值只在训练集上取，不在测试集上挑。

方法与步骤。 C1 阶段先读课程模板确认章节要求，据此排出章节分工表和图表清单，并建立实验日志模板。C2 阶段做天气消融：沿用成员 B 的特征接口，只切换天气开关，两个模型分别跑含天气与不含天气两组，梯度提升树直接读取已选定的配置以保证可比。C3 阶段做误差分析：先按区域算总体指标和相对指标，再按小时、星期、月份拆解，最后单独看高峰时段，阈值取训练集负荷分布的九十分位。C4 阶段把结论一条条对应到具体证据和图表上，写不出来的就不写。C5 阶段把各章并成完整稿并统一数字口径。

遇到的问题与解决。 有四个。

一是消融结果与主实验对不上。梯度提升树带天气那一组的指标和成员 B 的主实验有 0.3% 到 3.1% 的相对差异。查下来是我本机 scikit-learn 版本与成员 B 的 1.6.1 不同，直方图实现有数值微差。线性回归、样本区间、样本量全部逐值一致，说明不是流程问题。处理方式是先在实验日志里

注明版本差异并如实写进结论，随后全组在 `requirements.txt` 中锁定 `scikit-learn==1.6.1` 并重跑，偏差已消除，消融带天气组与主实验逐值一致。

二是高峰时段样本量不够。阈值按训练集九十分位取，结果到了测试期，区域 1 只剩 9 条高峰样本，区域 3 一条都没有，原因是测试期负荷整体下移。这两个区域的高峰表现确实无法从本次数据确认，我没有拿区域 2 的数字去外推，而是在报告里明确写成"无法确认"。

三是图里的减号显示成方框。残差分布图的坐标轴标签用了 Unicode 减号，黑体字库不支持，导出后是一个个小方块。换成 ASCII 减号后重新生成了三张图。

四是自己写错了一处结论。第 6.3 节初稿写"只有线性回归在区域 3 的 RMSE 优于基线"，核对 `improvement_vs_naive.csv` 后发现 MAE 同样占优（−2.69%），改成"两项指标同时占优"。这类错如果不逐列核对源文件是发现不了的，所以整合阶段我把报告里每个数字都回查了一遍原始结果文件。

不足。 版本统一后消融与误差分析都在新特征集上重做了一遍，但仍有两处留白：高峰时段结论只有区域 2 有足够样本支撑，区域 1 和区域 3 留白；误差分析只做到分层描述，没有进一步建模归因，误差与温度、负荷水平之间的定量关系还可以再做。另外时间特征目前取预测起点的小时、星期、月份，若改取目标时刻的对应值是否更合适，本次没有试验。

---

9 附录

附录 A 代码仓库

GitHub 仓库：https://github.com/77xiang/python_data_processing

代码结构：src/data_cleaning.py（清洗）→ src/features.py、src/splits.py（特征与切分）→ src/models.py、src/evaluate.py、src/compare.py（模型与比较）→ src/ablation.py（消融）→ src/error_analysis.py（误差分析）→ src/probe_target_week.py（归因实验）；分析图表分别由 src/eda.py、src/weather_analysis.py 生成。

附录 B 复现说明

1. 将原始数据放至 data/raw/题 4_城市电力负荷.csv（原始数据不入库）； 2. 依赖见 requirements.txt，其中 scikit-learn==1.6.1 必须锁定（梯度提升树数值随版本漂移，实测 1.6.1 与 1.9.1 之间相差 0.3%–3.1%）； 3. python src/compare.py 完整重跑三模型并生成表 3、图 7； 4. python src/probe_target_week.py 复现表 4（目标对齐周特征对照）并写出改进模型的测试集预测； 5. python src/ablation.py --target-week 复现表 5（新特征集上的天气消融），python src/ablation.py 复现原特征集消融； 6. python src/error_analysis.py --tag _tw 复现图 8 与误差分析（默认无 --tag 时分析原模型）； 7. 自动化检查：tests/（切分与特征索引含 purge 检查、模型对齐、交付核对共 20 项）。

附录 C 主要代码片段

以下为与本文结论直接相关的三段核心代码，完整实现见仓库对应文件。

（1）历史同期基线（src/models.py）：直接取目标时刻的上一周同期值，

NAIVE_LAG = 1008 − 6 = 1002。

```
def seasonal_naive_predict(load, origins):    """load: 负荷序列；origins: 预测起点行索引（协议保证 ≥ 1008）。"""    origins = np.asarray(origins, dtype=int)    if (origins - NAIVE_LAG).min() < 0:        raise ValueError("存在起点不足 7 天历史的样本，无法取上一周同期值")    return load[origins - NAIVE_LAG]  # ŷ(t+6) = y(t+6−1008) = y(t−1002)
```

（2）特征构造（src/features.py 的 build_zone_samples）：滞后特征只回溯起点及更早的观测；目标对齐周同期特征由 include_target_week 开关控制，天气特征由 include_weather 开关控制，供消融切换。

```
# 历史负荷滞后特征（相对起点 t 回溯，全部 ≤ t）for name, k in HISTORY_LAGS.items():
# load_lag_0/6/144/1008    X[name] = load[origins - k]# 目标时刻对齐的上周同期：y(t+6−1008) = y(t−1002)，与历史同期基线同源 if include_target_week:
X[TARGET_WEEK_LAG_NAME] = load[origins - TARGET_WEEK_LAG]# 天气特征：t 时刻同步观测（可用性假设见协议 3.3）if include_weather:    for col in WEATHER_COLUMNS:
X[col] = df[col].to_numpy(dtype=float)[origins]
```

（3）梯度提升树训练（src/models.py）：关闭内部早停（迭代数由验证集网格决定），固定种子保证可复现。

```
def train_gradient_boosting(X_train, y_train, *, seed=GBT_SEED,  # 42
max_iter=200, learning_rate=0.1, max_depth=None):    return
HistGradientBoostingRegressor(        max_iter=max_iter,
learning_rate=learning_rate, max_depth=max_depth,        early_stopping=False,
random_state=seed,    ).fit(X_train, y_train)
```